

## Mathias Exercice 1: Discrete distribution

Hardano

1) Pour générer une réalisation de la variable aléatoire  $X$ , il suffit d'appliquer la méthode d'inversion en calculant l'inverse généralisé de  $X$  donné par:

$$F^{\leftarrow}(u) = \inf \{ x \in \mathbb{R} : F(x) \geq u \} \quad \text{avec } F \text{ la f.d.r de } X \text{ et } u \in [0, 1]$$

$X$  étant d'une loi discrète, l'inverse généralisé est donné par:

$$\begin{aligned} F^{\leftarrow}(u) &= \inf \{ x \in \mathbb{R} : \sum_{i=1}^n p_i \mathbb{1}_{\{x_i \leq x\}} \geq u \} \\ &= \{ x_k : S_{k-1} < u \leq S_k \} \end{aligned}$$

$$\text{avec } S_0 = 0 \text{ et } S_k = \left( \sum_{i=1}^k p_i \right)$$

Et on a donc  $F^{\leftarrow}(u) \sim X$  pour  $u \sim \text{Unif}([0, 1])$



## Exercice 2: Gaussian mixture model

1) On identifie dans ce modèle :

$$\theta = (\alpha_1, \dots, \alpha_m, \mu_1, \dots, \mu_m, \Sigma_1, \dots, \Sigma_m)$$

De plus, on a :

$$\mathcal{L}(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f_\theta(x_i)$$

$$\stackrel{\text{formule des probabilités totales}}{=} \prod_{i=1}^n \sum_{j=1}^m P_\theta(X_i = x_i)$$

$$= \prod_{i=1}^n \sum_{j=1}^m P(Z_i = j) P(X_i = x_i | Z_i = j)$$

$$\mathcal{L}(x_1, \dots, x_n; \theta) = \prod_{i=1}^n \sum_{j=1}^m \alpha_j \phi(x_i; \mu_j, \Sigma_j)$$

où  $\phi(\cdot; \mu_j, \Sigma_j)$  est la densité de la loi normale multivariée  $\mathcal{N}(\mu_j, \Sigma_j)$

3) Calcul de  $\mathcal{L}$



hathas 3) Etape (E) :

harciano

$$Q(\theta, \theta_1) = E[\log P_\theta(Z, x) | x, \theta_1]$$

$$Q(\theta, \theta_1) = \sum_{i=1}^m E[\log P_\theta(Z_i, x_i) | x_i, \theta_1]$$

Replac:  $\log P_\theta(Z_i, x_i) = \sum_{j=1}^m \log(\alpha_j) + \log(f_{\theta_j}(x_i))$

où  $f$  est la densité de  $X$  comme dans l'énoncé

$$\Rightarrow \log P_\theta(Z_i, x_i) = \sum_{j=1}^m \log(\alpha_j) + \log(f_{\theta_j}(x_i))$$

$$\Rightarrow Q(\theta, \theta_1) = \sum_{i=1}^n \sum_{j=1}^m IP(Z_i=j | x_i, \theta_1) [\log(\alpha_j) + \log(f_{\theta_j}(x_i))]$$

$$Q(\theta, \theta_1) = \sum_{i=1}^n \sum_{j=1}^m p_{ij}(\theta_1) [\log(\alpha_j) + \log(f_{\theta_j}(x_i))]$$

avec  $p_{ij}(\theta_1) = IP(Z_i=j | x_i, \theta_1)$

En appliquant la formule de Bayes on a :

$$p_{ij}(\theta_1) = \frac{IP(Z_i=j) \phi(x_i | \theta_1, Z_i=j)}{\sum_{k=1}^m IP(Z_i=k) \phi(x_i | \theta_1, Z_i=k)}$$

$$p_{ij}(\theta_1) = \frac{\alpha_j \phi(x_i; \mu_j, \Sigma_j)}{\sum_{k=1}^m \alpha_k \phi(x_i; \mu_k, \Sigma_k)}$$

avec  $\phi(\cdot; \mu, \Sigma)$   
densité de la  
loi normale multi-  
dimensionnelle



Etape (M):

On sait que la valeur de  $\alpha_j$  qui maximise notre log-vraisemblance est sa probabilité d'appartenir à un cluster soit:

$$\alpha_j = \frac{\sum_{i=1}^n p_{ij}}{\sum_{k=1}^m \sum_{i=1}^n p_{ik}}$$

Cela vient de la résolution du problème de maximisation:

$$\left\{ \begin{array}{l} \max_{\alpha} \sum_{i=1}^n \sum_{j=1}^m p_{ij} (\log(\alpha_j) + \log(\phi(x_i; \mu_j, \Sigma_j))) \\ \text{tel que } \sum_{j=1}^m \alpha_j = 1 \end{array} \right.$$

Calcul de  $\mu$ : on résout

$$\max_{\mu} \sum_{j=1}^m \sum_{i=1}^n p_{ij} \left( \log(\alpha_j) + \log\left( \frac{1}{(2\pi|\Sigma_j|)^{1/2}} \exp\left(-\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j)\right) \right) \right)$$

$$= \max_{\mu} \sum_{j=1}^m \sum_{i=1}^n p_{ij} \left( \log(\alpha_j) - \frac{1}{2} (x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j) \right) + K$$

$\rightarrow$  constante par rapport à  $\mu$

C'est une fonction concave donc on résout la condition d'optimalité (gradient nul):

$$\sum_{i=1}^n p_{ij} (\Sigma_j^{-1} x_i - \Sigma_j^{-1} \mu_j) = 0$$



Mathur  $\Rightarrow \sum_{i=1}^n p_{ij} x_i = \sum_{i=1}^n p_{ij} \mu_j$

Marciano

$\Rightarrow \mu_j = \frac{\sum_{i=1}^n p_{ij} x_i}{\sum_{i=1}^n p_{ij}}$

Pour la matrice de covariance  $\Sigma_y$ , ma démo n'a pas abouti. Je prendrai donc le résultat du document de Telecom Paris dont le lien est dans mon notebook:

$\Sigma_y = \frac{\sum_{i=1}^n p_{ij} (x_i - \mu_j)^T (x_i - \mu_j)}{\sum_{i=1}^n p_{ij}}$



Matthias  
harciano

### Exercice 3: Importance sampling

$$(iii): \max_{\theta} \sum_{i=1}^n \tilde{w}_i^{(1)} \log \left( \sum_{j=1}^M \alpha_j \psi(X_i^{(1)}; \theta_j) \right)$$

qui est une approximation de  $\max_{\theta} \log \left( \sum_{i=1}^M \alpha_i \phi(x_i | \mu_i, \Sigma_i) \right)$  fGLM  
pour  $r(x)$  une certaine densité  
qui remplace les pondérations  $\tilde{w}_i^{(1)}$

Ce problème de maximisation ressemble à celui  
de l'exercice 2 où il ~~fallait~~ fallait maximiser  
la log-vraisemblance avec un modèle de mélange  
gaussien donc cela suggère qu'on peut résoudre  
ce problème grâce à l'algorithme EM en faisant  
quelques analogies et en prenant en compte les  
pondérations d'importance  $\tilde{w}_i^{(1)}$ ;

$$p_{ic} = \frac{\alpha_c \phi(x_i | \mu_c, \Sigma_c)}{\sum_{k=1}^M \alpha_k \phi(x_i | \mu_k, \Sigma_k)} \quad \phi \text{ densité d'une gaussienne multi-dimensionnelle}$$

$$\alpha_c = \frac{\sum_{i=1}^n p_{ic} \tilde{w}_i}{\sum_{k=1}^M \sum_{i=1}^n p_{ik} \tilde{w}_i}$$

$$\mu_c = \frac{\sum_{i=1}^n p_{ic} \tilde{w}_i x_i}{\sum_{i=1}^n p_{ic} \tilde{w}_i}$$

$$\Sigma_c = \frac{\sum_{i=1}^n p_{ic} \tilde{w}_i (x_i - \mu_c)^T (x_i - \mu_c)}{\sum_{i=1}^n p_{ic} \tilde{w}_i}$$